

Universidad Autónoma de la Ciudad de México

Notas de Probabilidad

Apuntes y ejercicios seleccionados

Carlos E Martínez-Rodríguez
Academia de Matemáticas
Plantel Casa Libertad
`carlos.martinez@uacm.edu.mx`

Índice

1. Fundamentos	1
-----------------------	----------

1. Fundamentos

Definición 1. Parámetro es una Característica de la población medias y varianzas en la dist. normal o binomial. Si se conocen sus valores o se puede aproximar con suficiente precisión, se puede responder cualquier pregunta sobre la probabilidad.

Definición 2. Estadístico: Cualquier función de la muestra, p.e. media o varianza muestral.

Definición 3. Estimadores: Son estadísticos indep. de los parámetros de la pob, y se utilizan para aprox. Si θ es el parámetro de interés, su estimador es denotado por $\hat{\theta}$.

Por ejemplo: dist normal para $\mu \leftarrow \bar{X} = \hat{\mu}$ y $\sigma^2 \leftarrow S^2 = \hat{\sigma}^2$. \bar{X} , S^2 son estimadores puntuales de μ y σ^2 p/dist. normal.

Definición 4. Muestreo: Se considerará el muestreo aleatorio simple para determinar el tamaño de la muestra, n .

Los estimadores se obtienen a partir de una MAS: X_1, X_2, \dots, X_n . de la v.a. \bar{X} . P/cada muestreo los res. serán dif., por ser realizados a partir de una muestra aleatoria, los estimadores son aleatorios y por tanto tienen una dist., se le denomina dist. de muestreo.

Ejemplo 1. Dist. Binomial:

Sup. $X \sim \text{Bin}(n, p)$, $p = P\{X = 1\}$, n = tamaño de la muestra.

Para determinar p se selecciona una MAS X_1, X_2, \dots, X_n de v.a. $\text{Bin}(1, p) = \text{Bern}(p)$. La proporción muestral está dada por:

$$\hat{p} = \sum_{i=1}^n \frac{X_i}{n}$$

Proporción muestral \hat{p} es una v.a. para n suf. grande:

$$\hat{p} \sim N \left(p, \frac{p(1-p)}{n} \right)$$

(Tmas límite)

El error típico: estimador

$$ET(\hat{p}) = \sqrt{\frac{p(1-p)}{n}},$$

p desconocido y por tanto $ET(\hat{p})$ también.

P.e. Si $X \sim \text{Bin}(15, p)$ y se quiere estimar p , lo es. P/aprox. se puede sustituir p por \hat{p} .

Tomar 100 muestras de tamaño 100 (X_1, X_2, \dots, X_{100}) y se calcula la prop. muestral en c/u de ellas, obt. 100 valores para \hat{p} .

$$\hat{\mu} = 0,7 \quad y \quad \hat{\sigma}^2 = \frac{0,7 \times 0,3}{100}$$

Ejemplo 2. 2) Dist. Normal $N(\mu, \sigma^2)$

Def.: $X \sim N(\mu, \sigma^2)$. Sup. X_1, X_2, \dots, X_n MAS, $X \sim N(\mu, \sigma^2)$.

$$\begin{aligned}\hat{\mu} &= \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad T.O. \\ \bar{X} &\sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \Rightarrow \quad Z_1 = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)\end{aligned}\tag{1}$$

Esto es válido si la varianza pob. σ^2 es conocida.

$$\begin{aligned}E(\bar{X}) &= \mu & ET(\bar{X}) &= \frac{\sigma}{\sqrt{n}}, \quad \text{ejemplo } n = 20, 100 \text{ y } 500 \\ && \Rightarrow & \bar{X} \sim N(\mu = 5, \sigma^2 = 4/n)\end{aligned}$$

Si σ^2 es desconocida,

$$\hat{\sigma}^2 \leftarrow S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \tag{2}$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \tag{3}$$

En (1) $\sigma^2 \rightarrow s^2$:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim \begin{cases} t_{n-1}, & n \leq 30 \\ N(0, 1), & n > 30 \end{cases}$$

y

$$ET(\bar{X}) = \frac{S}{\sqrt{n-1}} \simeq \frac{S}{\sqrt{n}} \quad (\text{error residual})$$

1) σ^2 conocida:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

2) σ^2 desc., $n > 30$:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0, 1)$$

3) σ^2 desc., $n \leq 30$:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

3) Est. de varianza σ^2 :

Si X_1, X_2, \dots, X_n MAS de v.a. $N(\mu, \sigma^2)$, entonces

$$\frac{nS^2}{\sigma^2} \sim \chi_n^2 \quad o \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Para n pequeña.

Si n es suf. grande se puede aprox χ_n^2 por $N(n, 2n)$.

Un estimador de un parámetro pob es función de la muestra.

Es preciso dar una definición de las prop. para que el estimador sea bueno.

Sea X_1, X_2, \dots, X_n una MAS de tamaño n , se dice que $\hat{\theta}$ es un estimador de θ si es estadístico calculado p/ cualquier parámetro desconocido es ese.

$$\hat{\theta} = h(X_1, X_2, \dots, X_n)$$

3) Sea X v.a. con dist. $F_X(x)$, $F_X(x; \theta)$, θ parámetro desconocido.

Sea X_1, X_2, \dots, X_n MAS de tamaño n . A $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ se le llama estimador puntual de θ , $\hat{\theta}$ es una v.a. por ser función de v.a. y por tanto tiene dist.

Al seleccionar una muestra, $\hat{\theta}$ toma un valor llamado estimación puntual.

Se dice que $\hat{\theta}$ es un estimador insesgado de θ si

$$E(\hat{\theta}) = \theta$$

Si $\hat{\theta}$ no es insesgado \Rightarrow

$$E(\hat{\theta}) - \theta$$

es el sesgo del estimador.

De los posibles estimadores, el de menor varianza es considerado mejor estimador (MVUE). Si es insesgado \Rightarrow (UMVUE) es mejor estimador de θ .

Para X_1, X_2, \dots, X_n MAS de $N(\mu, \sigma^2)$, μ es UMVUE.

Para X_1, X_2, \dots, X_n MAS de $N(\mu, \sigma^2)$,

$$\hat{\sigma}_{\hat{\theta}} = \sqrt{V(\hat{\theta})}$$

El error estándar.

Para MAS $N(\mu, \sigma^2)$,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{con error estándar}$$

$$\hat{\sigma}_{\bar{X}} = \frac{S}{\sqrt{n}}$$

Def. 1. Dado un espacio de probabilidad

$$(\Omega, \mathcal{A}, P),$$

una variable aleatoria.

Una v.a. X es una función

$$X : (\Omega, \mathcal{A}) \rightarrow \mathbb{R} \quad \text{t.q.} \quad A_x = \{\omega : X(\omega) \leq x\} \in \mathcal{A}, \quad \forall x \in \mathbb{R}.$$

Def. 2. Sea Ω espacio muestral, y v.a. La función de prob inducida por Y es

$$P_Y(y = y_i) = P[Y = y_i] = P_{\Omega}\{\omega \in \Omega : Y(\omega) = y_i\}.$$

El espacio muestral para Y es

$$S_Y = \{y_i \in \mathbb{R} \mid \exists s \in \Omega, Y(s) = y_i\}.$$

Def. La población es el conjunto (grupo) de elementos de los cuales se desea tener información. La muestra es una parte de la población bajo estudio.

Def. La función distribución acumulada (CDF) de la v.a. X es

$$F_X(x) = P[X \leq x], \quad \forall x \in \mathbb{R}.$$

$$F_X(x) = P[X \leq x] = P\{\omega : X(\omega) \leq x\}, \quad \forall x \in \mathbb{R}.$$

Prop. de la FDA (CDF) $F_X(\cdot)$:

a)

$$F_X(-\infty) = \lim_{x \rightarrow -\infty} F_X(x) = 0, \quad F_X(\infty) = \lim_{x \rightarrow \infty} F_X(x) = 1.$$

b) $F_X(\cdot)$ es monótona no decreciente, i.e.

$$F_X(a) \leq F_X(b), \quad \text{para } a < b.$$

c) $F_X(\cdot)$ es continua por la derecha:

$$\lim_{h \rightarrow 0^+} F_X(x + h) = F_X(x).$$

Def. Sea X v.a.

a) X es una v.a. discreta si sólo puede tomar una cantidad finita o numerable de valores distintos, i.e. su rango es discreto.

Def. de prob.: Sea \mathcal{A} σ -álgebra en Ω , $P : \mathcal{A} \rightarrow [0, 1]$ es una función de conjuntos t.q.

- 1) $P(A) \geq 0 \quad \forall A \in \mathcal{A}$
- 2) $P(\Omega) = 1$
- 3) Si $\{A_\alpha\}_{\alpha=1}^\infty$ son eventos mutuamente excluyentes,

$$A_\alpha \cap A_{\alpha'} = \emptyset \quad \text{para } \alpha \neq \alpha',$$

entonces

$$P\left(\bigcup_{\alpha=1}^{\infty} A_\alpha\right) = \sum_{\alpha=1}^{\infty} P(A_\alpha).$$

Def. Si X es una v.a. discreta con valores $x_1, x_2, \dots, x_n, \dots$, la función $f_X(\cdot)$ definida por

$$f_X(x) = \begin{cases} P[X = x_j], & x = x_j, \quad j = 1, 2, \dots \\ 0, & x \neq x_j \end{cases}$$

es llamada función de densidad discreta de X .

Los valores x_j son llamados puntos de masa de X y $f_X(x_j)$ son las masas asociadas a los puntos de masa x_j .

Theo. Si X es una v.a. discreta, $F_X(\cdot)$ puede obtenerse de $f_X(\cdot)$ y viceversa.

Nota: La CDF $F_X(\cdot)$ es una función escalón.

Def.

Def. Una v.a. X es continua si existe una función $f_X(\cdot)$ t.q.

$$F_X(x) = \int_{-\infty}^x f_X(u) du, \quad \forall x \in \mathbb{R}.$$

Def. Si X es una v.a. continua, la función

$$f_X(x) = \frac{d}{dx} F_X(x)$$

es llamada función de densidad de probabilidad de X .

Teo. Si X tiene densidad $f_X(\cdot)$, entonces

$$f_X(x) = \frac{d}{dx} F_X(x) = F'_X(x).$$

Def.

Def. Sea X v.a., la media de X , μ_X , $E[X]$ se define por

$$E[X] = \sum_{j=1}^{\infty} x_j f_X(x_j) \quad \text{VAD}$$

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx \quad \text{VAC}$$

Si g es una función de \bar{X} , entonces

$$E[g(X)] = \sum_{x:g(x) \geq 0} g(x) f_X(x)$$

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

siempre que la integral exista.

Def. Si $E[X^2]$ existe, entonces la varianza de la v.a. X es

$$\text{Var}(X) = V[X] = E[X - (E[X])^2]$$

y la desviación estándar

$$SD(X) = \sqrt{V[X]}.$$

Si $E[X^2]$ no existe, la varianza no existe.

Teo.

$$V[Y] = E[Y^2] - (E[Y])^2.$$

Def. Sea X v.a., $\mu_X = E[X]$, la varianza σ_X^2 se define por

$$\text{Var}[X] = \sum_{j=1}^{\infty} (x_j - \mu_X)^2 f_X(x_j)$$

$$\text{Var}[X] = \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x) dx.$$

Teo. Sea X v.a. entonces

- i) $E[c] = c$, c constante.
- ii) $E[cg(X)] = c E[g(X)]$.
- iii) $E[c_1g_1(X) + c_2g_2(X)] = c_1E[g_1(X)] + c_2E[g_2(X)]$.
- iv) $E[g_1(X)] \leq E[g_2(X)]$ si $g_1(x) \leq g_2(x) \forall x$.

Teo. Sea X v.a. con $g(\cdot) \geq 0$, $g : \mathbb{R} \rightarrow \mathbb{R}$,

$$P[g(X) \geq k] \leq \frac{E[g(X)]}{k}, \quad \forall k > 0.$$

(Chebyshov)

Corolario: (Des. Chebyshev) Si X v.a. con varianza finita,

$$P(|X - \mu_X| \geq r\sigma_X) = P((X - \mu_X)^2 \geq r^2\sigma_X^2) \leq \frac{1}{r^2}, \quad r > 0.$$

Obs.

$$P(|X - \mu_X| < r\sigma_X) \geq 1 - \frac{1}{r^2}.$$

Teo.

$$V[aY + b] = a^2V[Y].$$

Def. La FGM de la v.a. X es

$$M(t) = E[e^{tY}]$$

y por Taylor alrededor,

$$\mu_r = E[X^r] = \sum \int e^{ty} f(y) = \int_{-\infty}^{\infty} e^{ty} f_Y(y) dy.$$

La función característica (CF) de \bar{X}

$$C(t) = E[e^{itX}], \quad i = \sqrt{-1}.$$

Prop. Sea X v.a. con MGF $M_X(t)$ que existe para $|t| < b$, $b > 0$. Entonces

$$C(t) = M_X(it).$$

Def. Sean X, Y v.a., X, Y son v.a.i.d. $X \sim Y$ o $Y \sim F_X$ si $F_Y(y) = F_X(y)$, $\forall y \in \mathbb{R}$.

Prop. Sean X, Y v.a., X y Y son idénticamente distribuidas si se cumple cualquiera de las sig. condiciones:

- a) $F_X(y) = F_Y(y) \quad \forall y$
- b) $f_X(y) = f_Y(y) \quad \forall y$
- c) $C_X(t) = C_Y(t) \quad \forall t$
- d) $M_X(t) = M_Y(t) \quad \forall t$ en una vecindad de cero.

Def. El k -ésimo momento de X es $E[X^k]$ y su k -ésimo momento central es

$$E[(X - E[X])^k].$$

Teo. Sup. MGF $m(t)$ existe para $|t| < b$, b constante positiva. Sup. k -ésima derivada $m^{(k)}(t)$ existe para $|t| < b$. Entonces

$$E[X^k] = m^{(k)}(0).$$

Def. El q -ésimo cuantil de una v.a. \bar{X} , q_α , es el mínimo valor ξ t.q.

$$F_X(\xi) \geq q.$$

Def. La mediana de una v.a. \bar{X} , $\text{Med}_X = \xi_{0.5}$.

Nota. El 3er momento sobre la media es llamada medida de simetría o sesgo.

$$\gamma = \frac{\mu_3}{\sigma^3}$$

es el coeficiente de sesgo.

$$\frac{\mu_4}{\sigma^4} - 3$$

coeficiente de exceso de kurtosis.

Def. Sea $f(y) = f_Y(y | \theta)$ la PDF de Y v.a.

$$\mathcal{Y} = \{y \mid f(y) > 0\}$$

es el soporte de valores de Y .

Sea Θ el conjunto de parámetros θ de interés.

\mathcal{H} es el espacio de parámetros de Y .

Def. La función indicadora

$$\mathbf{1}_A(x) = \mathbf{1}(x \in A) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

Nota: Algunas PMF / PDF / CDF están restringidas solamente en el soporte. Apéndice 2.

Def. Sea $f_Y(y)$ PDF de Y v.a. Sup.

$$f_Y(y | \theta) = c(\theta) k(y | \theta),$$

entonces $k(y | \theta)$ es el kernel de f_Y y $c(\theta) > 0$ es el término constante que hace que f_Y sume / integre 1. Así,

$$\int_{-\infty}^{\infty} k(y | \theta) dy = \frac{1}{c(\theta)}.$$

$$\sum_{y \in \mathcal{Y}} k(y | \theta) = \frac{1}{c(\theta)}.$$

Sup. Y es v.a. con $f_Y(\cdot)$ PDF,

$$E[g(Y)] = \int_{-\infty}^{\infty} g(y) f(y | \theta) dy = \int_{y \in \text{soporte}} g(y) f(y | \theta) dy.$$

Sup. que desp. de operaciones,

$$E[g(Y)] = a c(\theta) \int_{-\infty}^{\infty} k(y | \theta) dy, \quad a \text{ cte.}$$

De manera similar si f_Y es PMF,

$$E[g(Y)] = \sum_{y \in \mathcal{Y}} g(y) f(y | \theta),$$

y soporte de Y .

Sup. que desp. operaciones algebraicas,

$$E[g(Y)] = a c(\theta) \sum_{y \in \mathcal{Y}} k(y | \tau), \quad a \text{ cte.}$$

$$\begin{aligned} \Rightarrow E[g(Y)] &= a c(\theta) \sum_{y \in \mathcal{Y}} \frac{c(\tau)}{c(\tau)} k(y | \tau) \\ &= a \frac{c(\theta)}{c(\tau)} \sum_{y \in \mathcal{Y}} c(\tau) k(y | \tau) = a \frac{c(\theta)}{c(\tau)}. \end{aligned}$$

Ej. La función $\zeta(v)$ tiene PMF

$$\begin{aligned} f(y) = P[Y = y] &= \frac{1}{y^v \zeta(v)}, \quad v > 1, y = 1, 2, 3, \dots \\ \zeta(v) &= \sum_{y=1}^{\infty} \frac{1}{y^v}. \end{aligned}$$

Luego, para $v > 1$,

$$\begin{aligned} E[Y] &= \sum_{y=1}^{\infty} y \frac{1}{\zeta(v)} \frac{1}{y^v} = \frac{1}{\zeta(v)} \sum_{y=1}^{\infty} y^{1-v} \\ &= \frac{\zeta(v-1)}{\zeta(v)} \sum_{y=1}^{\infty} \frac{1}{y^{v-1}} = \frac{\zeta(v-1)}{\zeta(v)}. \end{aligned}$$

Mezclas de distribuciones

Def. La dist. de una v.a. \bar{X} es una mezcla si la CDF de \bar{X} es de la forma

$$F_{\bar{X}}(x) = \sum_{i=1}^k \alpha_i F_{X_i}(x), \quad 0 < \alpha_i < 1, \quad \sum_{i=1}^k \alpha_i = 1, \quad k \geq 2,$$

y $F_{X_i}(x)$ es la CDF de una v.a. X_i , $i = 1, 2, \dots, k$.

Def. Sea \bar{X} v.a. con CDF $F_{\bar{X}}(x)$. Sea h función t.q. $E[h(\bar{X})]$ existe. Entonces

$$E[h(\bar{X})] = \int_{-\infty}^{\infty} h(x) dF_{\bar{X}}(x).$$

Prop.

a) Si \bar{X} es una v.a. discreta con PMF $f_{\bar{X}}(x)$, tiene soporte \mathcal{Y} , entonces

$$E[h(\bar{X})] = \int_{-\infty}^{\infty} h(x) dF_{\bar{X}}(x) = \sum_{y \in \mathcal{Y}} h(y) f_{\bar{X}}(y).$$

b) Si \bar{X} es una v.a. continua con CDF $F_{\bar{X}}(x)$ y PDF $f_{\bar{X}}(x)$, entonces

$$E[h(\bar{X})] = \int_{-\infty}^{\infty} h(x) dF_{\bar{X}}(x) = \int_{-\infty}^{\infty} h(x) f_{\bar{X}}(x) dx.$$

c) Si \bar{X} es una v.a. con dist. mezcla y

$$F_{\bar{X}}(x) = \sum_{i=1}^k \alpha_i F_{X_i}(x),$$

entonces

$$E[h(\bar{X})] = \int_{-\infty}^{\infty} h(x) dF_{\bar{X}}(x) = \sum_{i=1}^k \alpha_i E_{X_i}[h(X_i)].$$

Ej. Sup. CDF de X es

$$F_X(x) = (1 - \varepsilon) \Phi(x) + \varepsilon \Phi(x | k),$$

$0 < \varepsilon < 1$ y $\Phi(x)$ es la CDF de $W_1 \sim N(0, 1)$, entonces

$$\Phi(x | k)$$

es la CDF de $W_2 \sim N(0, k^2)$.

$E[Y] = ?$ Usar $h(y) = y$. Entonces

$$E[Y] = (1 - \varepsilon)E[W_1] + \varepsilon E[W_2] = (1 - \varepsilon)0 + \varepsilon(0) = 0.$$

Para encontrar $E[Y^2]$ utilizar $h(y) = y^2$.

$$E[Y^2] = (1 - \varepsilon)E[W_1^2] + \varepsilon E[W_2^2] = (1 - \varepsilon)1 + \varepsilon k^2 = 1 - \varepsilon + \varepsilon k^2.$$

Entonces

$$V[Y] = E[Y^2] - E^2[Y] = 1 - \varepsilon + \varepsilon k^2.$$

Distribución discreta.

1)

$$f(x) = f(x; N) = \begin{cases} \frac{1}{N}, & x = 1, 2, \dots, N, \\ 0, & \text{otro caso.} \end{cases}$$

X v.a. uniforme.

$$E[X] = \frac{N+1}{2}, \quad V[X] = \frac{N^2 - 1}{12}.$$

$$M_X(t) = E[e^{tX}] = \sum_{x=1}^N e^{tx} \frac{1}{N}.$$

2) Si X v.a. con

$$f_X(x) = f_X(x; p) = \begin{cases} p x^{p-1}, & 0 < x < 1, \\ 0, & \text{otro caso,} \end{cases} \quad 0 \leq p \leq 1,$$

$$F_X(x) = \int_0^x p t^{p-1} dt = x^p, \quad 0 < x < 1.$$

Sea $X \sim \text{Beta}(p)$.

$$E[X] = p, \quad V[X] = \frac{p(1-p)}{(p+1)}.$$

3) Sea X v.a. con

$$f_X(x) = f_X(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n.$$

$X \sim \text{Bin}(n, p)$.

$$E[X] = np, \quad V[X] = np(1-p).$$

4) Sea X v.a. con

$$f_X(x) = f_X(x; \lambda) = \frac{(\lambda x)^k e^{-\lambda x}}{k!}, \quad x = 0, 1, 2, \dots$$

$X \sim \text{Poisson}(\lambda)$.

$$E[X] = \lambda, \quad V[X] = \lambda.$$

5) Sea X v.a. con

$$f_X(x; \mu, n) = \frac{\left(\frac{n}{\mu}\right)^n x^{n-1} e^{-nx/\mu}}{(n-1)!}, \quad x > 0.$$

$X \sim \text{Gamma}(n, \mu)$.

$$E[X] = \mu, \quad V[X] = \frac{\mu^2}{n}.$$

6) Sea X v.a. con

$$f_X(x; \alpha, \beta) = \frac{1}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} e^{-(x/\beta)^\alpha}, \quad x > 0.$$

$X \sim \text{Weibull}(\alpha, \beta)$.

$$E[X] = \beta \Gamma\left(1 + \frac{1}{\alpha}\right), \quad V[X] = \beta^2 \left[\Gamma\left(1 + \frac{2}{\alpha}\right) - \Gamma^2\left(1 + \frac{1}{\alpha}\right) \right].$$

Distribuciones continuas

6) Binomial negativa

$$P(X = x \mid r, p) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \dots$$

$$E[X] = \frac{r}{p}, \quad \text{Var}[X] = \frac{r(1-p)}{p^2},$$

$$M_X(t) = \left(\frac{p}{1 - (1-p)e^t} \right)^r.$$

7) Distribución geométrica

$$P(X = x \mid p) = p(1-p)^{x-1}, \quad x = 1, 2, \dots$$

$$E[X] = \frac{1}{p}, \quad \text{Var}[X] = \frac{1-p}{p^2},$$

$$M_X(t) = \frac{pe^t}{1 - (1-p)e^t}.$$

8) Distribución uniforme

$$f(x \mid a, b) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{otro caso.} \end{cases}$$

$$E[X] = \frac{a+b}{2}, \quad \text{Var}[X] = \frac{(b-a)^2}{12},$$

$$M_X(t) = \frac{e^{bt} - e^{at}}{(b-a)t}.$$

9) Distribución gamma

$$f(x \mid \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad x > 0.$$

$$E[X] = \alpha\beta, \quad \text{Var}[X] = \alpha\beta^2,$$

$$M_X(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

10) Distribución exponencial ($\alpha = 1$)

$$f(x | \beta) = \frac{1}{\beta} e^{-x/\beta}, \quad x > 0.$$

$$E[X] = \beta, \quad \text{Var}[X] = \beta^2,$$

$$M_X(t) = \frac{1}{1 - \beta t}, \quad t < \frac{1}{\beta}.$$

5) Distribución Weibull

Sea $Y = X^{1/r}$.

$$f_Y(y | \beta) = \frac{r}{\beta^r} y^{r-1} e^{-(y/\beta)^r}, \quad y > 0, r > 0, \beta > 0$$

$$E[Y] = \beta \Gamma\left(1 + \frac{1}{r}\right), \quad \text{Var}[Y] = \beta^2 \left[\Gamma\left(1 + \frac{2}{r}\right) - \Gamma^2\left(1 + \frac{1}{r}\right) \right]$$

6) Distribución normal general

$$X \sim N(\mu, \sigma^2)$$

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$E[X] = \mu, \quad \text{Var}[X] = \sigma^2, \quad M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$$

7) Distribución Beta

$$f(x | \alpha, \beta) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1, \alpha > 0, \beta > 0$$

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

$$E[X] = \frac{\alpha}{\alpha+\beta}, \quad \text{Var}[X] = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

8) Distribución Gamma

$$f(x | \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad x > 0$$

$$E[X] = \alpha\beta, \quad \text{Var}[X] = \alpha\beta^2$$

$$M_X(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}$$

9) Dist. Lognormal

Sea X v.a. y sea $Y = \log X$ v.a.

$$\log X \sim N(\mu, \sigma^2)$$

$$f(x | \mu, \sigma^2) = \frac{1}{x\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right), \quad x > 0$$

$$E[X] = e^{\mu + \frac{\sigma^2}{2}}, \quad \text{Var}[X] = (e^{\sigma^2} - 1)e^{2\mu + \sigma^2}$$

10) Dist. Doble exponencial

$$f(x | \mu, b) = \frac{1}{2b} e^{-|x-\mu|/b}, \quad x \in \mathbb{R}, \quad b > 0$$

$$E[X] = \mu, \quad \text{Var}[X] = 2b^2$$

11) Distribución logística

$$f(x | \alpha, \beta) = \frac{e^{-(x-\alpha)/\beta}}{\beta(1+e^{-(x-\alpha)/\beta})^2}, \quad x \in \mathbb{R}, \quad \beta > 0$$

$$E[X] = \alpha, \quad \text{Var}[X] = \frac{\pi^2}{3}\beta^2$$

12) Dist. Pareto

$$f(x | x_0, \theta) = \frac{\theta x_0^\theta}{x^{\theta+1}}, \quad x \geq x_0, \quad \theta > 0$$

$$E[X] = \frac{\theta x_0}{\theta - 1}, \quad \theta > 1$$

$$\text{Var}[X] = \frac{\theta x_0^2}{(\theta - 1)^2(\theta - 2)}, \quad \theta > 2$$

13) Dist. Gumbel

$$f_X(x; \alpha, \beta) = \frac{1}{\beta} \exp\left(-\frac{x-\alpha}{\beta} - e^{-(x-\alpha)/\beta}\right), \quad \beta > 0$$

Distribución Normalizada

Sea

$$I = \int_{-\infty}^{\infty} e^{-z^2/2} dz$$

$$I^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(z_1^2+z_2^2)/2} dz_1 dz_2$$

Cambio a coordenadas polares:

$$z_1 = r \cos \theta, \quad z_2 = r \sin \theta, \quad dz_1 dz_2 = r dr d\theta$$

$$\begin{aligned} I^2 &= \int_0^{2\pi} \int_0^\infty e^{-r^2/2} r dr d\theta \\ &= \int_0^{2\pi} d\theta \int_0^\infty r e^{-r^2/2} dr \end{aligned}$$

Sea

$$u = \frac{r^2}{2} \Rightarrow du = r dr$$

$$\int_0^\infty r e^{-r^2/2} dr = \int_0^\infty e^{-u} du = 1$$

$$I^2 = 2\pi \Rightarrow I = \sqrt{2\pi}$$

$$\int_{-\infty}^\infty \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = 1$$

Sea X v.a. con f.d.p. $f(x)$.

I)

$$f(x) = xe^{-x^2/2}, \quad x > 0$$

II)

$$f(x) = \frac{1}{\sqrt{\pi}} e^{-x^2}, \quad x \in \mathbb{R}$$

III)

$$f(x) = \frac{4}{\pi} x^2 e^{-x^2}, \quad x > 0$$

IV)

$$f(x) = \frac{4}{\sqrt{\pi}} x^2 e^{-x^2}, \quad x > 0$$

V)

$$f(x) = 2xe^{-x^2}, \quad x > 0$$

VI)

$$f(x) = \frac{2}{\sqrt{\pi}} e^{-x^2}, \quad x > 0$$

VII)

$$f(x) = \frac{4}{\sqrt{\pi}} x e^{-x^2}, \quad x > 0$$

VIII)

$$f(x) = 2x^3 e^{-x^2}, \quad x > 0$$

IX)

$$f(x) = ce^{-x^2}, \quad x \in \mathbb{R}$$

X)

$$f(x) = kx^2 e^{-x^2}, \quad x > 0$$

—

Sea

$$I = \int_0^\infty e^{-z^2} dz$$

$$I^2 = \int_0^\infty \int_0^\infty e^{-(z_1^2+z_2^2)} dz_1 dz_2$$

Cambio a coordenadas polares:

$$z_1 = r \cos \theta, \quad z_2 = r \sin \theta, \quad dz_1 dz_2 = r dr d\theta$$

$$\begin{aligned} I^2 &= \int_0^{\pi/2} \int_0^\infty e^{-r^2} r dr d\theta \\ &= \int_0^{\pi/2} d\theta \int_0^\infty r e^{-r^2} dr \end{aligned}$$

Sea

$$u = r^2 \Rightarrow du = 2r dr$$

$$\int_0^\infty r e^{-r^2} dr = \frac{1}{2} \int_0^\infty e^{-u} du = \frac{1}{2}$$

$$I^2 = \frac{\pi}{4} \Rightarrow I = \frac{\sqrt{\pi}}{2}$$

$(X) dx \sim X$ i.s.

$$\frac{k}{T} = \theta = \left(\frac{2k}{T}, \frac{k}{T} \right) = \theta \leq \frac{2k}{T} = 0 \quad k = n$$

$$\frac{2k}{T} = 0 \leq \frac{2k}{T} = \frac{2k}{2} = \left(\frac{y}{T} \right) - \frac{2k}{2} = E[Y]$$

$$\frac{2k}{2} = \frac{k}{T} = M_X(1)$$

$$M_X(t) = \frac{2(x-t)}{2x(x-t)} = \frac{(x-t)}{2x(x-t)}$$

$$\frac{2(x-t)}{x}$$

$$M_X(t) = \frac{x-t}{x}$$

$$M_X(t) = \frac{2(x-t)}{x}$$

$$M_X(t) = \frac{x-t}{x}$$

$$M_X(t) = \frac{x-t}{x}$$

$$M'_X(t) = -\frac{1}{x}$$

$$M''_X(t) = \frac{2(x-t)}{x^2}$$

$$M'_X(1) = -\frac{1}{x}$$

$$\int_0^\infty e^{-(x-t)x} dx$$

$$\int_0^\infty x e^{-x^2} dx$$

$$\int_0^\infty x^2 e^{-x^2} dx$$

$$E[X] = \int_0^\infty x e^{-x^2} dx$$

$$E[X^2] = \int_0^\infty x^2 e^{-x^2} dx$$

$$K(X|\theta) \sim \exp(\theta)$$

$$K(X|\theta) = \lambda e^{-\lambda x}$$

$$f_X(x) = \lambda e^{-\lambda x}, \quad x > 0$$

$$\int_0^\infty \lambda e^{-\lambda x} dx$$

$$E[X] = \int_0^\infty x \lambda e^{-\lambda x} dx$$

$$= \frac{1}{\lambda}$$

$$E[X^2] = \int_0^\infty x^2 \lambda e^{-\lambda x} dx$$

$$= \frac{2}{\lambda^2}$$

$$V[X] = \frac{1}{\lambda^2}$$

$$f(x) = ke^{-2x}, \quad x > 0$$

$$\int_0^\infty ke^{-2x} dx$$

$$k = \frac{1}{2}$$

$$E[X] = \int_0^\infty x \frac{1}{2} e^{-2x} dx$$

$$= \frac{1}{4}$$

$$\theta = \frac{1}{\lambda}$$

$$\theta = \frac{X}{2}$$

$$\theta = \frac{X}{2}$$

$$K(\theta|X) \sim \exp(k)$$

(24)

$$\theta = (\mu, \sigma^2)$$

$$\lambda = \frac{1}{2}$$

$$X \sim \text{Exp}\left(\frac{1}{2}\right)$$

$$f_X(x; \theta)$$

$$\Phi = \begin{pmatrix} \mu = \frac{1}{\lambda} \\ \sigma^2 = \frac{1}{\lambda^2} \end{pmatrix}$$

$$f(x) = \frac{1}{2}e^{-x/2}, \quad x > 0$$

$$\int_0^\infty f(x) dx = \int_0^\infty \frac{1}{2}e^{-x/2} dx$$

$$u = \frac{x}{2} \quad \Rightarrow \quad du = \frac{1}{2}dx$$

$$\begin{aligned}
\int_0^\infty \frac{1}{2} e^{-x/2} dx &= \int_0^\infty e^{-u} du = 1 \\
E[X] &= \int_0^\infty x f(x) dx = \int_0^\infty x \frac{1}{2} e^{-x/2} dx \\
u = \frac{x}{2} \quad \Rightarrow \quad x &= 2u \\
E[X] &= \int_0^\infty 2ue^{-u} du \\
&= 2 \int_0^\infty ue^{-u} du \\
&= 2
\end{aligned}$$

$$\begin{aligned}
E[X^2] &= \int_0^\infty x^2 f(x) dx = \int_0^\infty x^2 \frac{1}{2} e^{-x/2} dx \\
&= \int_0^\infty 4u^2 e^{-u} du \\
&= 4 \int_0^\infty u^2 e^{-u} du \\
&= 8
\end{aligned}$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 8 - 4 = 4$$

$$\mu = 2, \quad \sigma^2 = 4$$

$$\begin{aligned}
M_X(t) &= \int_0^\infty e^{tx} \frac{1}{2} e^{-x/2} dx \\
&= \int_0^\infty \frac{1}{2} e^{x(t-1/2)} dx \\
&= \int_0^\infty \frac{1}{2} e^{-x(1/2-t)} dx \\
&= \frac{1}{2} \int_0^\infty e^{-x(1/2-t)} dx \\
&= \frac{1}{2} \cdot \frac{1}{(1/2-t)}
\end{aligned}$$

$$M_X(t) = \frac{1}{1-2t}$$

$$t < \frac{1}{2}$$

$$f_X(x) = x^{n-1} e^{-x/\lambda}$$

$$f_X(x) = x^{n-1} e^{-x/\lambda}$$

$$X \sim \text{Gamma}(n, \lambda)$$

$$\mathbb{E}[X] = n\lambda, \quad \text{Var}(X) = n\lambda^2$$

$$M_X(t) = \frac{1}{(1 - \lambda t)^n}$$

Supongamos ahora

$$f_X(x) = c x e^{-x^2}, \quad x \geq 0$$

Averiguar c .

$$\int_0^\infty c x e^{-x^2} dx = 1$$

Sea $u = x^2$, entonces $du = 2x dx$.

$$\int_0^\infty x e^{-x^2} dx = \frac{1}{2} \int_0^\infty e^{-u} du = \frac{1}{2}$$

Por lo tanto,

$$c = 2$$

Luego,

$$f_X(x) = 2x e^{-x^2}, \quad x \geq 0$$

$$\int_0^\infty e^{-x^2} dx = \frac{\sqrt{\pi}}{2}$$

$$\int_{-\infty}^\infty e^{-x^2} dx = \sqrt{\pi}$$

$$\int_0^\infty \int_0^\infty e^{-(x^2+y^2)} dx dy = \frac{\pi}{4}$$

Pasando a coordenadas polares:

$$x = r \cos \theta, \quad y = r \sin \theta$$

$$\int_0^{2\pi} \int_0^\infty e^{-r^2} r dr d\theta$$

$$\begin{aligned}
&= 2\pi \int_0^\infty r e^{-r^2} dr \\
&= 2\pi \cdot \frac{1}{2} = \pi
\end{aligned}$$

Def. Sea X una v.a. con función de distribución $F_X(x)$. Se define la función de probabilidad acumulada para X como

$$F_X(x) = \mathbb{P}(X \leq x).$$

Definición:

$$F_X(a, b) = \mathbb{P}(a < X \leq b).$$

Las funciones acumuladas $F_X(x)$ satisfacen las siguientes propiedades:

$$F_X(b) = \mathbb{P}(X \leq b), \quad F_X(a) = \mathbb{P}(X \leq a).$$

Entonces

$$F_X(a, b) = F_X(b) - F_X(a).$$

Caso discreto

Def. Sean (X_1, X_2) v.a. discretas. Se define la función de distribución conjunta como

$$F_{X_1, X_2}(x, y) = \mathbb{P}(X_1 \leq x, X_2 \leq y).$$

Def. La función de densidad de probabilidad conjunta de X_1, X_2 se denota por $f_{X_1, X_2}(x, y)$. La función de densidad marginal de X_1 es

$$f_{X_1}(x) = \sum_y f_{X_1, X_2}(x, y).$$

La función de densidad marginal de X_2 es

$$f_{X_2}(y) = \sum_x f_{X_1, X_2}(x, y).$$

Def. La función de densidad condicional de X_1 dado $X_2 = y$ es

$$f_{X_1|X_2}(x|y) = \frac{f_{X_1, X_2}(x, y)}{f_{X_2}(y)}, \quad f_{X_2}(y) > 0.$$

Análogamente,

$$f_{X_2|X_1}(y|x) = \frac{f_{X_1, X_2}(x, y)}{f_{X_1}(x)}, \quad f_{X_1}(x) > 0.$$

Def. Decimos que X, Y son continuas si existen funciones $f_{X,Y}(x, y)$ tales que

$$\forall A \subset \mathbb{R}^2, \quad \mathbb{P}\{(X, Y) \in A\} = \iint_A f_{X,Y}(x, y) dx dy.$$

$f_{X,Y}(x, y)$ es función de densidad de probabilidad conjunta de X y Y .

La densidad de X se obtiene observando

$$\mathbb{P}\{X \in \Delta\} = \int_{-\infty}^{\infty} \left(\int_{\Delta} f_{X,Y}(x, y) dx \right) dy = \int_{\Delta} f_X(x) dx.$$

De donde

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy.$$

Análogamente,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

Def. La densidad condicional de X dado $Y = y$ es

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad f_Y(y) > 0.$$

La densidad condicional de Y dado $X = x$ es

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x, y)}{f_X(x)}, \quad f_X(x) > 0.$$

Nota: La variable X_1, \dots, X_k se dice k -dimensional si

$$(x_1, \dots, x_k) \in \mathbb{R}^k.$$

Si existe una función de densidad conjunta $f_{X_1, \dots, X_k}(x_1, \dots, x_k)$, entonces

$$\mathbb{P}\{(X_1, \dots, X_k) \in A\} = \int \cdots \int_A f_{X_1, \dots, X_k}(x_1, \dots, x_k) dx_1 \cdots dx_k.$$

Def. La variable aleatoria (X_1, \dots, X_k) es absolutamente continua si existe $f_{X_1, \dots, X_k}(x_1, \dots, x_k)$ tal que

$$\mathbb{P}\{(X_1, \dots, X_k) \in A\} = \int \cdots \int_A f_{X_1, \dots, X_k}(x_1, \dots, x_k) dx_1 \cdots dx_k, \quad \forall A.$$

Nota: Sean (X_1, X_2) v.a. continuas en \mathbb{R}^2 , sea $f_{X_1, X_2}(x_1, x_2)$ su densidad conjunta.

$$\mathbb{P}\{(X_1, X_2) \in A\} = \iint_A f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

Sea

$$R = \{(x_1, x_2) : a_1 \leq x_1 \leq b_1, a_2 \leq x_2 \leq b_2\}.$$

Entonces

$$\mathbb{P}\{a_1 \leq X_1 \leq b_1, a_2 \leq X_2 \leq b_2\} = \int_{a_2}^{b_2} \int_{a_1}^{b_1} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

Ej. Considere

$$f(x, y) = k(x + y), \quad 0 < x < 1, 0 < y < 1,$$

y $f(x, y) = 0$ en otro caso.

Primero,

$$1 = \int_0^1 \int_0^1 k(x + y) dx dy.$$

Luego,

$$\int_0^1 \int_0^1 (x + y) dx dy = \int_0^1 \left(\int_0^1 x dx + \int_0^1 y dx \right) dy.$$

Se obtiene

$$k = \frac{1}{\frac{1}{2}} = 2.$$

Por lo tanto,

$$f(x, y) = 2(x + y).$$

Calcular:

$$\mathbb{P}\{X < \frac{1}{2}\} = \int_0^{1/2} \int_0^1 2(x + y) dy dx.$$

Además,

$$\int_0^{1/2} \int_0^1 2(x + y) dy dx = \frac{3}{8}.$$

$$\text{Vale } y = x + y.$$

Teo: Sean X, Y v.a.c.c. y $f_{X,Y}(x, y)$ su densidad conjunta. Se procede a obtener $f_X(x)$ y $f_Y(y)$.

Def:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

Def: Sean X, Y v.a.c.c. con densidad conjunta $f_{X,Y}(x, y)$. Entonces, para todo conjunto medible $A \subset \mathbb{R}$,

$$\mathbb{P}\{X \in A\} = \int_A \left(\int_{-\infty}^{\infty} f_{X,Y}(x, y) dy \right) dx.$$

Análogamente,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

Teo: Sean X_1, X_2, \dots, X_n v.a. independientes. Entonces la densidad conjunta es

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i), \quad x_i \geq 0.$$

Ej: Sea

$$f_{X,Y}(x, y) = 2(x + y), \quad 0 < x < 1, \quad 0 < y < 1.$$

Entonces

$$f_X(x) = \int_0^1 2(x + y) dy, \quad f_Y(y) = \int_0^1 2(x + y) dx.$$

Además,

$$\int_0^1 2(x+y) dy = 2x + 1.$$

$$\int_0^1 2(x+y) dx = 2y + 1.$$

Obs:

$$\int_0^1 f_X(x) dx = 1, \quad \int_0^1 f_Y(y) dy = 1.$$

$$\int_0^\infty \left(\int_0^\infty (x+y) dy \right) dx = \int_0^\infty \left[x + \frac{y^2}{2} \right]_0^\infty dx$$

$$f_X(x) = \int_0^\infty (x+y) dy$$

$$= \int_0^\infty x dy + \int_0^\infty y dy$$

$$= x \int_0^\infty dy + \int_0^\infty y dy$$

$$f_Y(y) = \int_0^\infty (x+y) dx$$

$$= \int_0^\infty x dx + y \int_0^\infty dx$$

$$\Rightarrow f_{X,Y}(x,y) = f_X(x)f_Y(y)$$

Ej: Una fábrica produce cuerdas que se venden y que se miden en metros. Sean X y Y las longitudes respectivas.

$$f_{X,Y}(x,y) = \frac{2}{3}(2x+3y), \quad 0 < x < 2, \quad 0 < y < 1$$

a)

$$f_X(x) = \int_0^1 \frac{2}{3}(2x+3y) dy$$

$$= \frac{2}{3} \left[2xy + \frac{3}{2}y^2 \right]_0^1$$

$$= \frac{2}{3} \left(2x + \frac{3}{2} \right)$$

$$f_Y(y) = \int_0^2 \frac{2}{3}(2x+3y) dx$$

$$= \frac{2}{3} [x^2 + 3xy]_0^2$$

$$= \frac{2}{3}(4 + 6y)$$

Sol:

a)

$$\mathbb{P}(X + Y \leq 1)$$

Ej:

Se seleccionan al azar 2 refrescos. Probabilidad de que ambos sean rojos.

Sean $X = \#$ de refrescos verdes, $Y = \#$ de refrescos rojos.

a)

$$\mathbb{P}((X, Y) \in \Delta) = ?$$

$$\Delta = \{(x, y) : x + y \leq 1\}$$

Sol:

$$\mathbb{R}^2 = \{(0, 0), (0, 1), (0, 2), (1, 0), (1, 1), (2, 0)\}$$

$$C_2^8 = \frac{8!}{2!6!}$$

$$f(0, 1) = \frac{(2)(1)(3)}{(3)(7)}$$

$$= \frac{6}{21}$$

$$f(0, 0) = \frac{(3)(2)}{(5)(7)}$$

$$= \frac{6}{35}$$

$$\frac{(3)(2)}{(5)(7)} = \frac{6}{35}$$

$$f_{X,Y}(x, y)$$

$X \setminus Y$	0	1	2	I
0	$\frac{7}{28}$	$\frac{3}{14}$	$\frac{7}{28}$	$\frac{1}{2}$
1	$\frac{4}{28}$	$\frac{3}{14}$	0	$\frac{15}{28}$
2	$\frac{3}{28}$	0	0	$\frac{3}{28}$
	$\frac{5}{14}$	$\frac{3}{7}$	$\frac{1}{28}$	

$$f_X(x)$$

$$\sum_{x,y} f_{X,Y}(x,y)$$

$$\sum_x f_X(x)$$

$$f_{X,Y}(x,y)$$

Ej: Definamos

$$f_{X,Y}(x,y) = \frac{2}{5}(2x + 3y), \quad \mathbf{1}_{\{0 \leq x \leq 1\}} \mathbf{1}_{\{0 \leq y \leq 1\}}$$

$$f_X(x) = \int_0^\infty f_{X,Y}(x,y) dy$$

$$f_X(x) = \int_0^1 \frac{2}{5}(2x + 3y) dy$$

$$f_Y(y) = \int_0^\infty f_{X,Y}(x,y) dx$$

$$f_Y(y) = \int_0^1 \frac{2}{5}(2x + 3y) dx$$

Def:

Sea X, Y v.a. con Δ dist. continua.

Dado que $X = x$ se tiene

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}, \quad f_X(x) > 0$$

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}, \quad f_Y(y) > 0$$

Notas:

$$\mathbb{P}(a < X < b \mid Y = y) = \int_a^b f_{X|Y}(x|y) dx$$

Ej: 3.18 (libro)

$$f_{X,Y}(x,y) = \frac{3}{7}$$

$$f_{X,Y}(x,1) = \frac{f_{X,Y}(x,1)}{f_Y(1)}$$

$$f_{X|Y}(x|1) = \frac{f_{X,Y}(x, 1)}{f_Y(1)} = \frac{3}{7}$$

$$f_{X|Y}(x|1) = f_{X,Y}(x, 1) + f_{X,Y}(2, 1)$$

$$= \frac{3}{7}$$

Nota:

\$x\$	0	1	2
\$f_X(x)\$	$\frac{1}{2}$	$\frac{1}{2}$	0

$$f_{X,Y}(x, y) = 10xy^2 \mathbf{1}_{\{0 \leq x \leq 1\}} \mathbf{1}_{\{0 \leq y \leq 1\}}$$

$$f_X(x) = ?$$

$$f_Y(y) = ?$$

Ej: Sea \$X, Y\$ v.a.

$$f_X(x) = \int_0^\infty f_{X,Y}(x, y) dy$$

$$f_X(x) = \int_0^1 10xy^2 dy$$

$$f_Y(y) = \int_0^\infty f_{X,Y}(x, y) dx$$

$$f_Y(y) = \int_0^1 10xy^2 dx$$

$$\Rightarrow f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

$$\mathbb{P}\left(\frac{1}{2} < X < 1\right) = \int_{1/2}^1 f_{X|Y}(x|y) dx$$

Observa:

$$f_{X|Y}(x|0)$$

$$f_{X|Y}(x|1)$$

$$f_{X|Y}(x|2)$$

$$f_Y(y) = \begin{cases} \frac{15}{28}, & y = 0 \\ \frac{3}{7}, & y = 1 \\ \frac{3}{28}, & y = 2 \end{cases}$$

$$f_X(0) = \frac{15}{28}$$

$$f_X(1) = \frac{3}{7}$$

$$f_X(2) = \frac{3}{28}$$

$$f_{X|Y}(y) = f_X(x|y)$$

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

$$f_X(x) = \int f_{X,Y}(x,y) dy \quad f_Y(y) = \int f_{X,Y}(x,y) dx$$

$$\mathbb{P}\left\{\frac{1}{2} < X < 1 \mid Y = \frac{1}{2}\right\} = \int_{1/2}^1 f_{X|Y}(x|y) dx$$

Ejercicios

3,40, 3,41, 3,42, 3,43, 3,44

3,45, 3,49, 3,50, 3,53, 3,63

3,68

Marque verdaderas

$$f_{X,Y}(x,y) = \frac{1}{500} \quad 0 \leq x \leq y \leq 200$$

Ejercicio

$$\mathbb{P}\{1 \leq X \leq 2\}$$

$$f_X(x) = \int_0^\infty f_{X,Y}(x,y) dy$$

$$f_Y(y) = \int_0^\infty f_{X,Y}(x,y) dx$$

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

Ej:

$$f_X(x) = \int_0^\infty f_{X,Y}(x,y) dy$$

$$f_Y(y) = \int_0^\infty f_{X,Y}(x,y) dx$$

$$f_{X|Y}(x|y)$$

Continúa Nota 1

	$f_{Y X}(y x)$	$f_X(x)$	$f_{X,Y}(x,y)$
$x = 0$	$\frac{3}{10}$	$\frac{3}{14}$	$\frac{3}{28}$
$x = 1$	$\frac{3}{5}$	$\frac{15}{28}$	$\frac{15}{28}$
$x = 2$	$\frac{1}{10}$	0	0

$$f_X(0) = \frac{3}{14}$$

$$f_X(1) = \frac{15}{28}$$

$$f_X(2) = \frac{3}{28}$$

$$f_{X|Y}(x|y) = \frac{2x}{3}, \quad x \in (0, 2)$$

$$f_X(x) = \int_0^2 f_{X|Y}(x|y) dy, \quad f_Y(y) = \int_0^2 f_{X|Y}(x|y) dx$$

$$f_{X|Y}(x|y)$$

$$f_{Y|X}(y|x)$$

Teorema

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}, \quad f_Y(y) \neq 0$$

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}, \quad f_X(x) \neq 0$$

Ejemplos, Muestreos y Ejercicios

Ejs: 4,4, 4,6, 4,8, 4,9, 4,10

Proposición

$f_{Y|X}(y|x)$ es una función de densidad condicional

cuando x es un número fijo

y para todo x cumple con las propiedades de una densidad.

Proposición

$f_{Y|X}(\cdot|x)$ es positiva (no negativa)

$$\int_{-\infty}^{\infty} f_{Y|X}(y|x) dy = 1$$

$$\int_{-\infty}^{\infty} \frac{f_{X,Y}(x,y)}{f_X(x)} dy = 1$$

$$\frac{1}{f_X(x)} \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy = 1$$

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy$$

Nota: En $f_{Y|X}(\cdot|x)$, x es fija y permite considerarla como una distribución acumulada.

Def: Función de dist. acumulada condicional

Si X, Y son V.A.C.C., la dist. acumulada condicional de Y dado $X = x$ se define por

$$F_{Y|X}(y|x) = \int_{-\infty}^y f_{Y|X}(t|x) dt, \quad x \in \mathbb{R}, \quad f_X(x) > 0.$$

Sup:

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}.$$

Ej:

$$f_{Y|X}(y|x) = \int_0^y \frac{2x+t}{x+\frac{1}{2}} dt, \quad 0 \leq y \leq 1.$$

$$f_{Y|X}(y|x) = \frac{1}{x+\frac{1}{2}} \int_0^y (2x+t) dt = \frac{1}{x+\frac{1}{2}} \left(2xy + \frac{y^2}{2} \right).$$

Recordando:

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}.$$

$$f_{X,Y}(x,y) = f_{Y|X}(y|x)f_X(x).$$

Si X y Y son independientes, entonces

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

$$\Rightarrow f_{Y|X}(y|x) = f_Y(y).$$

$$f_{Y|X}(y|x) dy = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy.$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dx.$$

$$f_{X,Y}(x,y) = f_X(x)f_Y(y)$$

Def: Sean X, Y V.A.D.C. o V.A.C.C. con densidades $f_{X,Y}(x,y)$ y marginales $f_X(x)$, $f_Y(y)$.

X y Y son estocásticamente independientes si y solo si

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

Ej: Retomar Ej. 3 p. 20 y 3 p. 24 y verificar si X, Y son independientes.

Def: Sean (X_1, X_2, \dots, X_k) V.A. discretas o continuas. X_1, X_2, \dots, X_k son estocásticamente independientes si

$$f_{X_1, X_2, \dots, X_k}(x_1, x_2, \dots, x_k) = f_{X_1}(x_1)f_{X_2}(x_2)\cdots f_{X_k}(x_k).$$

Def: Sean (X_1, X_2, \dots, X_k) V.A. discretas o continuas. X_1, X_2, \dots, X_k son estocásticamente independientes si

$$f_{X_i|X_j}(x_i|x_j) = f_{X_i}(x_i), \quad i \neq j.$$

Ej: Inferir

$$f_{X,Y}(x,y) = e^{-(2x)}e^{-(y)}, \quad x > 0, y > 0.$$

Luego:

$$f_{X,Y}(x,y) = f_X(x)f_Y(y) \quad (\text{VERIFICAR})$$

$$f_{X,Y}(x,y) = f_X(x)f_Y(y)$$

Def: Sean X, Y VADC o VACC con $f_{X,Y}(x,y)$ y densidades marginales $f_X(x)$ y $f_Y(y)$. X, Y son estocásticamente independientes si y solo si

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

Ej: Probar si 3 R.V. X_1, X_2, X_3 son independientes. Verificar si

$$f_{X_1, X_2, X_3}(x_1, x_2, x_3) = f_{X_1}(x_1)f_{X_2}(x_2)f_{X_3}(x_3).$$

Def: Sean (X_1, X_2, \dots, X_k) un vector aleatorio. Son estocásticamente independientes si

$$f_{X_1, \dots, X_k}(x_1, \dots, x_k) = \prod_{i=1}^k f_{X_i}(x_i).$$

Def: Sean (X_1, X_2, \dots, X_k) V.A. discretas. Son estocásticamente independientes si

$$p_{X_1, \dots, X_k}(x_1, \dots, x_k) = \prod_{i=1}^k p_{X_i}(x_i).$$

Ej: Sea

$$f_{X,Y}(x, y) = e^{-(x+y)}.$$

Teo: Sean X_1, X_2, \dots, X_k V.A. independientes y $g_1(\cdot), g_2(\cdot), \dots, g_k(\cdot)$ sean funciones tales que $Y_i = g_i(X_i)$, $i = 1, 2, \dots, k$. Entonces Y_1, \dots, Y_k son independientes.

Esperanza

Def: Sean X, Y V.A. con densidad conjunta $f_{X,Y}(x, y)$. Se define

$$\mathbb{E}[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f_{X,Y}(x, y) dx dy.$$

Teo: Si $g(X, Y) = X$, entonces

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x) dx.$$

Ej: Sea

$$f_{X,Y}(x, y) = e^{-(x+y)}, \quad x > 0, y > 0.$$

Calcular

$$\mathbb{E}[X].$$

$$\mathbb{E}[X] = \int_0^{\infty} \int_0^{\infty} x e^{-(x+y)} dx dy = \int_0^{\infty} x e^{-x} \left(\int_0^{\infty} e^{-y} dy \right) dx = \int_0^{\infty} x e^{-x} dx.$$

$$\mathbb{E}[X] = 1.$$

Ej: Sea

$$g(X, Y) = X + Y.$$

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

$$\mathbb{E}[X + Y] = \int_0^{\infty} \int_0^{\infty} (x + y) f_{X,Y}(x, y) dx dy = \int_0^{\infty} \int_0^{\infty} (x + y) e^{-(x+y)} dx dy = 2.$$

Prop:

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y].$$

Teo: Sean X, Y V.A. independientes. Sea $g(X, Y) = g(X)h(Y)$. Entonces

$$\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)] \mathbb{E}[h(Y)].$$

Dem:

$$\begin{aligned} \mathbb{E}[g(X)h(Y)] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y) f_{X,Y}(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y) f_X(x)f_Y(y) dx dy \\ &= \left(\int_{-\infty}^{\infty} g(x)f_X(x) dx \right) \left(\int_{-\infty}^{\infty} h(y)f_Y(y) dy \right) \\ &= \mathbb{E}[g(X)] \mathbb{E}[h(Y)]. \end{aligned}$$

Sup:

$$f_{X,Y}(x, y) = f_X(x)f_Y(y).$$

Ej:

$$\mathbb{E}[X + Y] =$$

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

Def: (Covarianza)Sean X, Y V.A. con varianzas finitas.

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)],$$

donde $\mu_X = \mathbb{E}[X]$ y $\mu_Y = \mathbb{E}[Y]$.**Def:** (Correlación)El coeficiente de correlación de X y Y se define por

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

donde $\sigma_X > 0$ y $\sigma_Y > 0$.**Nota:**

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

$$\begin{aligned} \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] &= \mathbb{E}[XY] - \mu_Y \mathbb{E}[X] - \mu_X \mathbb{E}[Y] + \mu_X \mu_Y \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]. \end{aligned}$$

Nota: Si X, Y son independientes, entonces

$$\text{Cov}(X, Y) = 0.$$

Ej: Funcional para X, Y .

$$f_{X,Y}(x, y) = (x + y) \mathbf{1}_{(0,1)}(x) \mathbf{1}_{(0,1)}(y).$$

Def: Sean X_1, X_2, \dots, X_k funciones aleatorias con

$$\mathbb{E}[X_i] = \mu_i, \quad i = 1, \dots, k.$$

Los momentos centrales están definidos por

$$\mathbb{E}[(X_1 - \mu_1) \cdots (X_k - \mu_k)].$$

Def: (Función generadora de momentos)

$$M_{X_1, \dots, X_k}(t_1, \dots, t_k) = \mathbb{E}\left[\exp\left(\sum_{i=1}^k t_i X_i\right)\right].$$

Nota: Las funciones generadoras satisfacen

$$\mathbb{E}[g(X, Y)] = \iint g(x, y) f_{X,Y}(x, y) dx dy.$$

Ej:

Sea $X = \mathbf{1}_A$, con $A \in \mathcal{F}$.

$$\mathbb{E}(X) = \mathbb{E}[\mathbf{1}_A] = P(A).$$

$$X^2 = X \Rightarrow \mathbb{E}(X^2) = \mathbb{E}(X).$$

$$\text{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = P(A) - P(A)^2 = P(A)(1 - P(A)).$$

Prop: Sean X_1, \dots, X_n V.A. independientes.

a) $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$.

b) $\sigma_X^2 = \text{Var}(X)$.

c) $\sigma_{X+Y}^2 = \sigma_X^2 + \sigma_Y^2$.

Prop:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i).$$

$$\text{Cov}(X_i, X_j) = 0, \quad i \neq j.$$

Corolario:

Sean X_1, X_2, \dots, X_n V.A. independientes. Entonces

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i).$$

Def: Sean X_1, X_2, \dots, X_n V.A. independientes i.i.d. Entonces

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

es una V.A. y se llama *media muestral*.

Prop: Si X_1, X_2, \dots, X_n son V.A. i.i.d. con

$$\mathbb{E}(X) = \mu, \quad \text{Var}(X) = \sigma^2,$$

entonces:

a) $\mathbb{E}(\bar{X}) = \mu.$

b) $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$

c) $\text{Cov}(X_i, \bar{X}) = \frac{\sigma^2}{n}.$

Def:

b)

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{\sigma^2}{n}.$$

c)

$$\text{Cov}(X_i, \bar{X}) = \text{Cov}\left(X_i, \frac{1}{n} \sum_{j=1}^n X_j\right) = \frac{1}{n} \text{Cov}(X_i, X_i) = \frac{\sigma^2}{n}.$$

Corolario:

Sean X_1, X_2, \dots, X_n V.A. independientes. Entonces

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i).$$

Def: Sean X_1, X_2, \dots, X_n V.A. i.i.d. Entonces

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

es una V.A. y se llama *media muestral*.

Prop: Si X_1, X_2, \dots, X_n son V.A. i.i.d. con

$$\mu = \mathbb{E}(X), \quad \sigma^2 = \text{Var}(X),$$

entonces:

a) $\mathbb{E}(\bar{X}) = \mu.$

b) $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$.

c) $\text{Cov}(X_i, \bar{X}) = \frac{\sigma^2}{n}$.

Def:

b)

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{\sigma^2}{n}.$$

c)

$$\text{Cov}(X_i, \bar{X}) = \text{Cov}\left(X_i, \frac{1}{n} \sum_{j=1}^n X_j\right) = \frac{1}{n} \text{Cov}(X_i, X_i) = \frac{\sigma^2}{n}.$$

$$\begin{aligned} \iint h(y) f_Y(y) f_X(x) dx dy &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(y) f_Y(y) f_X(x) dx dy \\ &= \int_{-\infty}^{\infty} h(y) f_Y(y) \left(\int_{-\infty}^{\infty} f_X(x) dx \right) dy \\ &= \int_{-\infty}^{\infty} h(y) f_Y(y) dy \end{aligned}$$

Sea $Z = X + Y$.

$$X, Y \text{ V.A. indep.} \Rightarrow f_{X,Y}(x,y) = f_X(x)f_Y(y)$$

$$f_Z(z) = \int_{-\infty}^{\infty} f_{X,Y}(x, z-x) dx = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

Propiedades

Traslación u unid.

Proporcionalidad u/n unid.

Prácticas $2q/n$ unid.

$$\frac{1}{n} \text{Cov}\left(\sum_{i=1}^n X_i, X_j\right) = \frac{1}{n} \text{Cov}(X_j, X_j) = \frac{\sigma^2}{n}$$

$$\frac{1}{n} \text{Cov}\left(\sum_{i=1}^n X_i, X_i\right) = \frac{1}{n} \sigma^2$$

$$\frac{1}{n} \operatorname{Cov}\left(\sum_{i=1}^n X_i, X_i\right) - \frac{\sigma^2}{n} = 0$$

para todo valor válido.

$$\int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy$$

n.e. la f.d.p. de la convolución

$$X + Y$$

Definimos

$$\begin{aligned} f_{X+Y}(a) &= \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy \\ &= \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy \end{aligned}$$

Ej:

$$X, Y \sim U(0, 1)$$

$$f_{X+Y}(a) = \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy$$

$$\text{si } 0 < a < 1$$

$$f_{X+Y}(a) = \int_0^a 1 dy$$

$$= a$$

$$\text{si } 1 < a < 2$$

$$f_{X+Y}(a) = \int_{a-1}^1 1 dy$$

$$= 2 - a$$

$$f_{X+Y}(a) = \begin{cases} a, & 0 < a < 1, \\ 2 - a, & 1 < a < 2. \end{cases}$$

$$a \in (0, 1) \quad a \in (1, 2)$$

$$\int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy$$

n.e. la f.d.p. de la convolución

$$X + Y$$

Definimos

$$\begin{aligned} f_{X+Y}(a) &= \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy \\ &= \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy \end{aligned}$$

Ej:

$$X, Y \sim U(0, 1)$$

$$f_{X+Y}(a) = \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy$$

$$\text{si } 0 < a < 1$$

$$f_{X+Y}(a) = \int_0^a 1 dy$$

$$= a$$

$$\text{si } 1 < a < 2$$

$$f_{X+Y}(a) = \int_{a-1}^1 1 dy$$

$$= 2 - a$$

$$f_{X+Y}(a) = \begin{cases} a, & 0 < a < 1, \\ 2 - a, & 1 < a < 2. \end{cases}$$

$$a \in (0, 1) \quad a \in (1, 2)$$

Ej 2: X, Y v.a. ind

$$f_{X+Y}(n)$$

$$0 \leq k \leq n$$

Caso $X + Y = n \iff X = k, Y = n - k$

$$\begin{aligned}
P(X + Y = n) &= \sum_{k=0}^n P(X = k, Y = n - k) \\
&= \sum_{k=0}^n P(X = k) P(Y = n - k) \\
&= \sum_{k=0}^n \frac{\lambda_1^k}{k!} e^{-\lambda_1} \frac{\lambda_2^{n-k}}{(n-k)!} e^{-\lambda_2} \\
&= e^{-(\lambda_1 + \lambda_2)} \sum_{k=0}^n \frac{\lambda_1^k \lambda_2^{n-k}}{k!(n-k)!} \\
&= e^{-(\lambda_1 + \lambda_2)} \frac{1}{n!} \sum_{k=0}^n \binom{n}{k} \lambda_1^k \lambda_2^{n-k} \\
&= e^{-(\lambda_1 + \lambda_2)} \frac{(\lambda_1 + \lambda_2)^n}{n!}
\end{aligned}$$

$$X + Y \sim P(\lambda_1 + \lambda_2)$$

V.A.C.C.

X_1, X_2 V.A.C.C. con densidad $f_{X_1, X_2}(x_1, x_2)$
Sup. $Y_1 = g_1(x_1, x_2), \quad Y_2 = g_2(x_1, x_2)$ T-Q

$$y_1 = y_1(x_1, x_2), \quad y_2 = y_2(x_1, x_2)$$

A) se pueden resolver las ecuaciones en forma única

para x_1 y x_2

$$x_1 = h_1(y_1, y_2), \quad x_2 = h_2(y_1, y_2)$$

B) las funciones y_1, y_2 tienen derivadas parciales $\forall(x_1, x_2)$

$$J(x_1, x_2) = \begin{vmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{vmatrix} \neq 0$$

Entonces Y_1 y Y_2 son V.A.C.C.

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(x_1, x_2) |J(x_1, x_2)|$$

$$x_1 = h_1(y_1, y_2), \quad x_2 = h_2(y_1, y_2)$$

Ej:

Sean X i.i.d. V.A. con

$$X \sim \text{Ga}(\alpha, \lambda), \quad Y \sim \text{Ga}(\beta, \lambda), \quad U = X + Y, \quad V = \frac{X}{X + Y}.$$

$$f_{X,Y}(x, y) = \frac{\lambda^\alpha e^{-\lambda x} x^{\alpha-1}}{\Gamma(\alpha)} \frac{\lambda^\beta e^{-\lambda y} y^{\beta-1}}{\Gamma(\beta)}$$

Sea

$$y_1 = g_1(x, y) = x + y, \quad y_2 = g_2(x, y) = \frac{x}{x + y}.$$

Entonces

$$\begin{aligned} \frac{\partial y_1}{\partial x} &= 1, & \frac{\partial y_1}{\partial y} &= 1, \\ \frac{\partial y_2}{\partial x} &= \frac{y}{(x+y)^2}, & \frac{\partial y_2}{\partial y} &= -\frac{x}{(x+y)^2}. \end{aligned}$$

$$U = x + y, \quad V = \frac{x}{x + y} \Rightarrow x = uv, \quad y = u(1 - v).$$

$$x = uv$$

$$v = \frac{uv}{uv + u(1 - v)} = uv$$

$$uv = uv \Rightarrow v = uv + u(1 - v)$$

$$uv = u$$

$$v = uv$$

$$\Rightarrow v = uv + u(1 - v)$$

$$\Rightarrow y = u(1 - v).$$

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(x_1, x_2) |J(x_1, x_2)|^{-1}$$

Donde

$$\begin{aligned} |J(x_1, x_2)|^{-1} &= \left| \begin{array}{cc} \frac{1}{x} & \frac{1}{y} \\ \frac{x}{(x+y)^2} & \frac{y}{(x+y)^2} \end{array} \right|^{-1} = \frac{xy}{(x+y)^2} = \frac{1}{x+y} \\ &= \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} e^{-\lambda(x+y)} x^{\alpha-1} y^{\beta-1} (x+y) \end{aligned}$$

$$\begin{aligned}
&= \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} e^{-\lambda u} (uv)^{\alpha-1} (u(1-v))^{\beta-1} u \\
&= \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (\lambda e^{-\lambda u}) (u^{\alpha-1} u^\beta) (v^{\alpha-1} (1-v)^{\beta-1}) \\
&= \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (\lambda e^{-\lambda u}) (\lambda u)^{\alpha-1} (\lambda u)^\beta v^{\alpha-1} (1-v)^{\beta-1} \\
&= \frac{\lambda e^{-\lambda u} (\lambda u)^{\alpha+\beta-1}}{\Gamma(\alpha+\beta)} \cdot \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} v^{\alpha-1} (1-v)^{\beta-1} \\
&\quad U \sim \text{Ga}(\alpha + \beta, \lambda), \quad V \sim \text{Be}(\alpha, \beta).
\end{aligned}$$

Sean X, Y v.a. c.c. con densidad

$$Z = XY$$

$$f_Z(z) = \int_{-\infty}^{\infty} \frac{1}{|y|} f_{X,Y}\left(\frac{z}{y}, y\right) dy$$

Sean X, Y v.a. c.c. con densidad

$$Z = X + Y, \quad V = X - Y$$

$$x = \frac{z+v}{2}, \quad y = \frac{z-v}{2}$$

$$\begin{aligned}
f_{Z,V}(z,v) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x,y) dx dy \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}\left(\frac{z+v}{2}, \frac{z-v}{2}\right) |J| dz dv \\
f_X(w) &= \int_{-\infty}^{\infty} f_{X,Y}(x, x-w) dx \\
&= \int_{-\infty}^{\infty} f_{X,Y}(x, x-v) dx
\end{aligned}$$

Sean X, Y variables aleatorias i.i.d.

$$\text{Var}(X - Y)$$

Entonces:

$$\mathbb{E}(X - Y) = \mathbb{E}(X) - \mathbb{E}(Y)$$

y

$$\begin{aligned}\text{Var}(X - Y) &= \mathbb{E}[(X - Y)^2] - [\mathbb{E}(X - Y)]^2 \\ &= \mathbb{E}(X^2 - 2XY + Y^2) - [\mathbb{E}(X - Y)]^2 \\ &= \mathbb{E}(X^2) - 2\mathbb{E}(XY) + \mathbb{E}(Y^2) - [\mathbb{E}(X - Y)]^2\end{aligned}$$

Def:

$$\mathbb{E}(X^2) = \text{Var}(X) + [\mathbb{E}(X)]^2$$

$$\mathbb{E}(Y^2) = \text{Var}(Y) + [\mathbb{E}(Y)]^2$$

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y) \quad (\text{i.i.d.})$$

Así:

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) + [\mathbb{E}(X)]^2 + [\mathbb{E}(Y)]^2 - 2\mathbb{E}(X)\mathbb{E}(Y) - (\mathbb{E}(X) - \mathbb{E}(Y))^2$$

$$= \text{Var}(X) + \text{Var}(Y)$$

$\boxed{\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y)}$

$$\Rightarrow \mathbb{E}[XY] = \mu_X\mu_Y + \mu_Y\mathbb{E}[X - \mu_X] + \mu_X\mathbb{E}[Y - \mu_Y] + \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

$$\mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mu_X\mu_Y + \text{Cov}(X, Y)$$

$$\mathbb{E}[(XY)^2] = \sim\sim\sim$$

Cor: Si X, Y son indep.

$$\mathbb{E}[XY] = \mu_X \mu_Y$$

y

$$\text{Var}(XY) = \mu_Y^2 \text{Var}(X) + \mu_X^2 \text{Var}(Y) + \text{Var}(X)\text{Var}(Y)$$

Tarea: $\mathbb{E}\left[\frac{X}{Y}\right]$

Ej: Sea $X \sim \mathcal{N}(0, 1)$. Sea $Y = X^2 = g(X)$

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y})$$

$$\begin{aligned} &= \Phi(\sqrt{y}) - \Phi(-\sqrt{y}) = 2 \int_0^{\sqrt{y}} \phi(u) du \\ &= \frac{2}{\sqrt{2\pi}} \int_0^{\sqrt{y}} e^{-u^2/2} du \end{aligned}$$

$$u = \sqrt{z} \iff u^2 = z \Rightarrow 2u du = dz$$

$$du = \frac{dz}{2\sqrt{z}}$$

$$0 \leq u^2 \leq y \Rightarrow 0 \leq z \leq y$$

$$\frac{2}{\sqrt{2\pi}} \int_0^y \frac{e^{-z/2}}{2\sqrt{z}} dz = \frac{1}{\sqrt{\pi}} \int_0^y \frac{e^{-z/2}}{\sqrt{2z}} dz$$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

$$X \sim \Gamma(\alpha, \beta) \Rightarrow f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$$

$$\alpha = \frac{1}{2}, \quad \beta = 2$$

$$\Rightarrow \int_0^y \frac{e^{-z/2}}{\Gamma(\frac{1}{2})\sqrt{2z}} dz$$

Sea $X \sim \mathcal{N}(0, 1)$, $Y = X^2$

—

$$\begin{aligned} \mathbb{E}(Y) &= \mathbb{E}(X^2) = \int_{-\infty}^{\infty} x^2 e^{-x^2/2} dx \\ &= \int_{-\infty}^{\infty} e^{-x^2/2} x^2 dx \\ &= \left[-xe^{-x^2/2} \right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-x^2/2} dx \\ &= 0 + \sqrt{2\pi} \end{aligned}$$

$$\Rightarrow \mathbb{E}(Y) = 1$$

—

Por $X \sim \mathcal{N}(0, 1)$ $\Rightarrow Y = X^2 \sim \chi^2_{(1)}$

—

$$Y_1 = g_1(X_1, X_2) , \quad Y_2 = X_1 + X_2$$

(Transformación uno-a-uno)

—

$$\begin{aligned} \mathbb{E}[e^{t_1 Y_1 + t_2 Y_2}] &= \mathbb{E}[e^{t_1(X_1^2 + X_2^2) + t_2(X_1 + X_2)}] \\ &= \mathbb{E}[e^{t_1 X_1^2 + t_2 X_1}] \mathbb{E}[e^{t_1 X_2^2 + t_2 X_2}] \end{aligned}$$

—

$$\begin{aligned} M_{Y_1, Y_2}(t_1, t_2) &= \mathbb{E}[e^{t_1(X_1^2 + X_2^2) + t_2(X_1 + X_2)}] \\ &= \mathbb{E}[e^{t_1 X_1^2 + t_2 X_1}] \mathbb{E}[e^{t_1 X_2^2 + t_2 X_2}] \end{aligned}$$

—

$$M(t_1, t_2) = \exp\left(\frac{t_2^2}{2(1 - 2t_1)}\right) \cdot \frac{1}{\sqrt{1 - 2t_1}}$$

—

$$= \exp\left(\frac{t_2^2}{1-2t_1}\right) \cdot \frac{1}{1-2t_1}$$

—

$$M(t_1, t_2) = \frac{1}{1-2t_1} \exp\left(\frac{t_2^2}{1-2t_1}\right)$$

—

$$M(t) = \mathbb{E}(e^{tY}) = e^{2t^2/2} = e^{t^2}$$

$$\Rightarrow Y \sim \mathcal{N}(0, 2)$$

Sea $X_1, X_2 \sim \mathcal{N}(0, 1)$ independientes

$$Z = \frac{X_2 - X_1}{\sqrt{2}}$$

—

$$\text{Sea } Y = X_2 - X_1$$

$$\Rightarrow Y \sim \mathcal{N}(0, 2)$$

—

Por binomiales:

$$M_Y(t) = M_{X_2-X_1}(t) = M_{X_2}(t) M_{-X_1}(t)$$

$$= \left(e^{t^2/2}\right) \left(e^{t^2/2}\right) = e^{t^2}$$

—

$$\Rightarrow Y \sim \mathcal{N}(0, 2)$$

—

$$\text{Sea } Z = \frac{X_2 - X_1}{\sqrt{2}}$$

$$M_Z(t) = \mathbb{E}(e^{tZ}) = \mathbb{E}\left(e^{t(X_2-X_1)/\sqrt{2}}\right)$$

$$= M_Y\left(\frac{t}{\sqrt{2}}\right) = e^{(t/\sqrt{2})^2} = e^{t^2/2}$$

—

$$\Rightarrow Z \sim \mathcal{N}(0, 1)$$

— Suma de normales

$$M_{X+Y}(t) = M_X(t) M_Y(t) = e^{\mu_X t + \sigma_X^2 t^2/2} e^{\mu_Y t + \sigma_Y^2 t^2/2}$$

$$= e^{(\mu_X + \mu_Y)t + (\sigma_X^2 + \sigma_Y^2)t^2/2}$$

$$\Rightarrow X + Y \sim \mathcal{N}(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$$

Resultado:

Sean $Z_1, Z_2, \dots, Z_n \sim \mathcal{N}(0, 1)$ independientes.

Sean $a_{ij} \in \mathbb{R}$,

$$i = 1, 2, \dots, m, \quad j = 1, 2, \dots, n$$

Sea $\mu_i \in \mathbb{R}$, $i = 1, 2, \dots, m$.

— **Definición:**

$$X_1 = \sum_{j=1}^n a_{1j} Z_j + \mu_1$$

$$X_2 = \sum_{j=1}^n a_{2j} Z_j + \mu_2$$

⋮

$$X_m = \sum_{j=1}^n a_{mj} Z_j + \mu_m$$

En general,

$$X_k = \sum_{j=1}^n a_{kj} Z_j + \mu_k, \quad k = 1, 2, \dots, m$$

— **Entonces:**

$$X_k \sim \mathcal{N}\left(\mu_k, \sum_{j=1}^n a_{kj}^2\right)$$

— **Luego:**

$$M_{X_1+X_2+\dots+X_m}(t_1, t_2, \dots, t_m) = \mathbb{E} [e^{t_1 X_1 + t_2 X_2 + \dots + t_m X_m}]$$

$$M_{\sum_{j=1}^m X_j}(t_1, t_2, \dots, t_m) = \mathbb{E} [e^{\sum_{j=1}^m t_j X_j}]$$

A saber:

$$\begin{aligned} \mathbb{E} \left[\sum_{j=1}^m t_j X_j \right] &= \sum_{j=1}^m \mathbb{E}[t_j X_j] = \sum_{j=1}^m t_j \mathbb{E}[X_j] \\ &= \sum_{j=1}^m t_j \mu_j \end{aligned}$$

$$\begin{aligned} \text{Var} \left(\sum_{j=1}^m t_j X_j \right) &= \text{Cov} \left(\sum_{j=1}^m t_j X_j, \sum_{j=1}^m t_j X_j \right) \\ &= \sum_{j=1}^m \sum_{i=1}^m \text{Cov}(X_i, X_j) t_i t_j \end{aligned}$$

Ejemplo:

Sean X_1, X_2 v.a. independientes con distribución $\mathcal{N}(0, 1)$.

Sea

$$Y = \frac{(X_2 - X_1)^2}{2}$$

y encontrar la distribución de Y .

Función generadora de momentos de Y :

$$\begin{aligned} M_Y(t) &= \mathbb{E} [e^{tY}] = \mathbb{E} \left[e^{\frac{(X_2 - X_1)^2}{2} t} \right] \\ &= \mathbb{E} \left[\exp \left(\frac{X_2^2 - 2X_1 X_2 + X_1^2}{2} t \right) \right] \end{aligned}$$

Como $X_1, X_2 \sim \mathcal{N}(0, 1)$ independientes,

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2\pi} \exp \left(-\frac{x_1^2 + x_2^2}{2} \right)$$

$$M_Y(t) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp \left(\frac{(x_2 - x_1)^2}{2} t \right) \exp \left(-\frac{x_1^2 + x_2^2}{2} \right) dx_1 dx_2$$

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp \left(\frac{x_2^2(t-1) + x_1^2(t-1) - 2x_1x_2t}{2} \right) dx_1 dx_2$$

—

Reordenando términos:

$$= \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp \left(\frac{x_2^2(1-t)}{2} \right) \left[\int_{-\infty}^{\infty} \exp \left(-\frac{(1-t)}{2} \left(x_1^2 + \frac{2x_1x_2t}{1-t} \right) \right) dx_1 \right] dx_2$$

Ejemplo (continuación):

Sean X_1, X_2 v.a. independientes con distribución $\mathcal{N}(0, 1)$. Sea

$$Y = \frac{(X_2 - X_1)^2}{2}$$

y encontrar la distribución de Y .

—

Función generadora de momentos:

$$\begin{aligned} M_Y(t) &= \mathbb{E}[e^{Yt}] = \mathbb{E}\left[e^{\frac{(X_2-X_1)^2}{2}t}\right] \\ &= \mathbb{E}\left[\exp\left(\frac{X_2^2 - 2X_1X_2 + X_1^2}{2}t\right)\right] \end{aligned}$$

—

Como $X_1, X_2 \sim \mathcal{N}(0, 1)$ independientes,

$$\begin{aligned} &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp\left(\frac{(x_2-x_1)^2}{2}t\right) \exp\left(-\frac{x_1^2+x_2^2}{2}\right) dx_1 dx_2 \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp\left\{\frac{x_2^2(t-1) + x_1^2(t-1) + 2x_1x_2t}{2}\right\} dx_1 dx_2 \end{aligned}$$

—

Reescribiendo:

$$= \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp\left(\frac{x_2^2(1-t)}{2}\right) \left[\int_{-\infty}^{\infty} \exp\left(-\frac{(1-t)}{2} \left(x_1^2 + \frac{2x_1x_2t}{1-t} \right) \right) dx_1 \right] dx_2$$

—

Factorizando y completando cuadrados en la integral interna:

$$= \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp\left(\frac{x_2^2(1-t)}{2}\right) \left[\int_{-\infty}^{\infty} \exp\left(-\frac{(1-t)}{2} \left(x_1 + \frac{x_2t}{1-t} \right)^2\right) dx_1 \right] dx_2$$

Evaluando la integral gaussiana:

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{1-t}} \exp\left(-\frac{x_2^2}{2} \frac{1-t-t^2}{1-t}\right) dx_2$$

—

$$= \frac{1}{\sqrt{1-t}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_2^2}{2(1-2t)}\right) dx_2$$

Finalmente:

$$M_Y(t) = (1-2t)^{-1/2}, \quad t < \frac{1}{2}$$

Teorema. Sean X_1, X_2, \dots, X_n v.a. independientes t.q. su FGM existe $\forall |t| < h$, p.a. $h > 0$. Sea

$$Y = \sum_{i=1}^n X_i.$$

Entonces,

$$M_Y(t) = \mathbb{E}\left[e^{\sum_{i=1}^n X_i t}\right] = \prod_{i=1}^n M_{X_i}(t), \quad |t| < h.$$

Demostración.

$$\begin{aligned} M_Y(t) &= \mathbb{E}\left[\exp\left(\sum_{i=1}^n X_i t\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{X_i t}\right] \\ &= \prod_{i=1}^n \mathbb{E}[e^{X_i t}] = \prod_{i=1}^n M_{X_i}(t). \end{aligned}$$

Ejemplo. Sean X_1, X_2, \dots, X_n v.a. independientes con distribución $\text{Ber}(p)$.

$$M_X(t) = pe^t + q,$$

entonces,

$$M_{\sum X_i}(t) = \prod_{i=1}^n M_{X_i}(t) = (pe^t + q)^n.$$

Se tiene que

$$\sum_{i=1}^n X_i \sim \text{Binomial}(n, p).$$

Ejemplo. Sean X_1, X_2, \dots, X_n v.a. independientes con

$$X_i \sim \text{Po}(\lambda_i).$$

$$M_{X_i}(t) = \mathbb{E}[e^{X_i t}] = \exp(\lambda_i(e^t - 1)).$$

Entonces,

$$\begin{aligned} M_{\sum X_i}(t) &= \prod_{i=1}^n M_{X_i}(t) = \prod_{i=1}^n \exp(\lambda_i(e^t - 1)) \\ &= \exp\left(\sum_{i=1}^n \lambda_i(e^t - 1)\right), \quad \text{i.e. } \sum_{i=1}^n X_i \sim \text{Po}\left(\sum_{i=1}^n \lambda_i\right). \end{aligned}$$

Teorema. Sean X_1, X_2, \dots, X_n v.a. independientes t.q. su FGM existe $\forall |t| < h$, p.a. $h > 0$. Sea

$$Y = \sum_{i=1}^n X_i.$$

Entonces,

$$M_Y(t) = \mathbb{E}[e^{\sum_{i=1}^n X_i t}] = \prod_{i=1}^n M_{X_i}(t), \quad |t| < h.$$

Demostración.

$$\begin{aligned} M_Y(t) &= \mathbb{E}\left[\exp\left(\sum_{i=1}^n X_i t\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{X_i t}\right] \\ &= \prod_{i=1}^n \mathbb{E}[e^{X_i t}] = \prod_{i=1}^n M_{X_i}(t). \end{aligned}$$

Ejemplo. Sean X_1, X_2, \dots, X_n v.a. independientes con distribución $\text{Ber}(p)$.

$$M_X(t) = pe^t + q,$$

entonces,

$$M_{\sum X_i}(t) = \prod_{i=1}^n M_{X_i}(t) = (pe^t + q)^n, \quad \text{i.e. } Y = \sum_{i=1}^n X_i.$$

Se tiene distribución

$$\text{Binomial}(n, p).$$

Ejemplo. Sean X_1, X_2, \dots, X_n v.a. independientes con

$$X_i \sim \text{Po}(\lambda_i).$$

$$M_{X_i}(t) = \mathbb{E}[e^{X_i t}] = \exp(\lambda_i(e^t - 1)).$$

$$M_{\sum X_i}(t) = \prod_{i=1}^n M_{X_i}(t) = \prod_{i=1}^n \exp(\lambda_i(e^t - 1))$$

$$= \exp\left(\sum_{i=1}^n \lambda_i(e^t - 1)\right), \quad \text{i.e. } Y \sim \text{Po}\left(\sum_{i=1}^n \lambda_i\right).$$

Ejemplo. Sean X_1, X_2, \dots, X_n v.a. independientes con distribución $\text{Exp}(\lambda)$. Entonces,

$$M_{X_i}(t) = \frac{\lambda}{\lambda - t},$$

y por lo tanto,

$$M_Y(t) = \prod_{i=1}^n M_{X_i}(t) = \prod_{i=1}^n \left(\frac{\lambda}{\lambda - t}\right) = \left(\frac{\lambda}{\lambda - t}\right)^n.$$

i.e.

$$Y \sim \text{Ga}(n, \lambda).$$

Ejemplo. Sean X_1, X_2, \dots, X_n v.a. independientes t.q.

$$X_i \sim \mathcal{N}(\mu_i, \sigma_i^2),$$

entonces

$$a_i X_i \sim \mathcal{N}(a_i \mu_i, a_i^2 \sigma_i^2),$$

y

$$M_{a_i X_i}(t) = \exp\left(a_i \mu_i t + \frac{1}{2} a_i^2 \sigma_i^2 t^2\right).$$

Entonces,

$$M_{\sum_{i=1}^n a_i X_i}(t) = \prod_{i=1}^n M_{a_i X_i}(t) = \exp\left(\sum_{i=1}^n a_i \mu_i t + \frac{1}{2} \sum_{i=1}^n a_i^2 \sigma_i^2 t^2\right).$$

i.e.

$$Y \sim \mathcal{N}\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right).$$

Resultado. Si

$$X \sim \mathcal{N}(\mu_x, \sigma_x^2), \quad Y \sim \mathcal{N}(\mu_y, \sigma_y^2),$$

y X, Y son independientes, entonces

$$X + Y \sim \mathcal{N}(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2),$$

$$X - Y \sim \mathcal{N}(\mu_x - \mu_y, \sigma_x^2 + \sigma_y^2).$$

Tema: (Teorema Central del Límite)

(Tema límite central)

Sea $n \in \mathbb{N}$, X_1, X_2, \dots, X_n sean v.a. i.i.d. con media μ_X y varianza σ_X^2 finitas $\forall i$.

Entonces,

$$F_{Z_n}(z) \longrightarrow \Phi(z) \quad \text{cuando } n \rightarrow \infty.$$

Donde

$$Z_n = \frac{\bar{X}_n - \mathbb{E}[\bar{X}_n]}{\sqrt{\text{Var}(\bar{X}_n)}} = \frac{\bar{X}_n - \mu_X}{\sigma_X / \sqrt{n}}.$$

Para n fijo, el valor de la FDP de Z_n ($n = 1, 2, \dots$) converge al valor $\phi(z)$.

Corolario: Si X_1, X_2, \dots, X_n son v.a. i.i.d. con media μ_X y varianza σ_X^2 finitas, entonces

$$\mathbb{P}\left(a < \frac{\bar{X}_n - \mu_X}{\sigma_X / \sqrt{n}} < b\right) \approx \Phi(b) - \Phi(a).$$

Nota: Recordemos que para $Y = g(X)$,

$$f_Y(y) = \left| \frac{d}{dy} g^{-1}(y) \right| f_X(g^{-1}(y)) \mathbf{1}_D(y).$$

Ej: Sup. $X \sim \text{Be}(\alpha, \beta)$, ¿cómo se distribuye

$$Y = -\log_e X ?$$

Se tiene

$$y = -\ln x \Rightarrow x = e^{-y}, \quad y = \ln x^{-1} \Rightarrow e^y = x^{-1}.$$

Luego,

$$x = g^{-1}(y) = e^{-y}, \quad \frac{dx}{dy} = -e^{-y}.$$

Por la fórmula de transformación,

$$f_Y(y) = \left| \frac{d}{dy} g^{-1}(y) \right| f_X(g^{-1}(y)).$$

Como

$$f_X(x) = \frac{1}{\text{Be}(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1},$$

entonces

$$f_Y(y) = e^{-y} \frac{1}{\text{Be}(\alpha, \beta)} (e^{-y})^{\alpha-1} (1-e^{-y})^{\beta-1}.$$

Simplificando,

$$f_Y(y) = \frac{1}{\text{Be}(\alpha, \beta)} e^{-\alpha y} (1-e^{-y})^{\beta-1}.$$

Si $\beta = 1$, se tiene

$$f_Y(y) = \frac{1}{\text{Be}(\alpha, 1)} e^{-\alpha y}.$$

Además,

$$\text{Be}(\alpha, 1) = \frac{\Gamma(\alpha)\Gamma(1)}{\Gamma(\alpha+1)} = \frac{1}{\alpha}.$$

Por tanto,

$$f_Y(y) = \alpha e^{-\alpha y}, \quad Y \sim \text{Exp}(\alpha).$$

Ej: Sea X v.a. con densidad Pareto, i.e.

$$f_X(x) = \theta x^{-\theta-1} \mathbf{1}_{(1,\infty)}(x),$$

y

$$Y = \log_e X = \ln X.$$

Entonces

$$y = \ln x, \quad x = e^y, \quad dx = e^y dy.$$

Luego,

$$f_Y(y) = e^y \theta (e^y)^{-\theta-1} \mathbf{1}_{(0,\infty)}(y) = \theta e^{-\theta y} \mathbf{1}_{(0,\infty)}(y).$$

Ej: Sean X_1, X_2 v.a. independientes,

$$X_1, X_2 \sim N(0, 1).$$

Definimos

$$Y_1 = X_1 + X_2, \quad Y_2 = \frac{X_1}{X_2}.$$

Entonces,

$$x_1 = g_1^{-1}(y_1, y_2) = \frac{y_1 y_2}{1 + y_2}, \quad x_2 = g_2^{-1}(y_1, y_2) = \frac{y_1}{1 + y_2}.$$

Las transformaciones directas son

$$g_1(x_1, x_2) = x_1 + x_2, \quad g_2(x_1, x_2) = \frac{x_1}{x_2}.$$

Derivadas parciales:

$$\begin{aligned} \frac{\partial g_1}{\partial x_1} &= 1, & \frac{\partial g_1}{\partial x_2} &= 1, \\ \frac{\partial g_2}{\partial x_1} &= \frac{1}{x_2}, & \frac{\partial g_2}{\partial x_2} &= -\frac{x_1}{x_2^2}. \end{aligned}$$

El jacobiano es

$$|J| = \begin{vmatrix} 1 & 1 \\ \frac{1}{x_2} & -\frac{x_1}{x_2^2} \end{vmatrix} = \left| -\frac{x_1}{x_2^2} - \frac{1}{x_2} \right| = \left| -\frac{x_1 + x_2}{x_2^2} \right|.$$

Por lo tanto,

$$|J| = \frac{x_1 + x_2}{x_2^2}.$$

Luego,

$$|J^{-1}| = \frac{x_2^2}{x_1 + x_2}.$$

Sustituyendo

$$x_2 = \frac{y_1}{1 + y_2}, \quad x_1 + x_2 = y_1,$$

se obtiene

$$|J^{-1}| = \frac{\left(\frac{y_1}{1+y_2}\right)^2}{y_1} = \frac{y_1}{(1+y_2)^2}.$$